UNIVERSIDAD PERUANA UNIÓN
FACULTAD DE INGENIERÍA Y ARQUITECTURA
Escuela Profesional de Ingeniería de Sistemas



Pronóstico mensual de la producción de cacao en el Perú mediante modelos de aprendizaje automático y validación temporal

Por:
Frank Pretel Ramos Arisapana

Docente:
Dr. Esteban Tocto Cano

Juliaca, noviembre de 2026

Índice

1. Planteamiento del Problema **3**
1.1. Identificación y formulación del problema . . . 3
1.2. Objetivos . . . 4
1.3. Hipótesis . . . 5
1.4. Justificación . . . 5
1.5. Antecedentes . . . 6
1.6. Marco conceptual . . . 6

2. Metodología **7**
2.1. Enfoque, tipo y diseño de investigación . . . 7
2.2. Fuente de datos y cobertura . . . 7
2.3. Unidad de análisis y variables . . . 8
2.4. Control de calidad y trazabilidad . . . 9
2.5. Ingeniería de características . . . 9
2.6. Modelos a evaluar . . . 9
2.7. Esquema de validación temporal . . . 9
2.8. Ajuste de hiperparámetros y prevención de fuga . . . 10
2.9. Métricas y criterio de comparación . . . 10
2.10. Procedimiento de trabajo . . . 10
2.11. Resultados preliminares de factibilidad . . . 11
2.12. Reproducibilidad y evidencias en GitHub . . . 12
2.13. Matriz de consistencia . . . 12
2.14. Aspectos éticos . . . 12

3. Administración del Proyecto **13**
3.1. Cronograma de actividades . . . 13
3.2. Productos esperados . . . 13
3.3. Gestión de evidencias . . . 13
3.4. Presupuesto proyectado . . . 14

4. Referencias Bibliográficas **14**

1. Planteamiento del Problema

1.1. Identificación y formulación del problema

El cacao (*Theobroma cacao* L.) es un cultivo permanente producido en distintas regiones del Perú y su volumen cambia durante el año. Esta variación responde a patrones estacionales y a diferencias territoriales, además de condiciones productivas que no se comportan igual entre regiones. Cuando el análisis se realiza solo con totales anuales, parte de ese comportamiento mensual queda oculto y se reduce la información disponible para anticipar periodos posteriores.

La literatura muestra que el pronóstico de cacao ya ha sido abordado con modelos estadísticos, aprendizaje automático y aprendizaje profundo. Olofintuyi et al. evaluaron una arquitectura que combina CNN, RNN y LSTM para estimar rendimiento de cacao [1]; Porras y Ovalle propusieron una LSTM para producción de cacao peruano [2]; y trabajos recientes han incorporado variables climáticas, ambientales y genéticas para estudiar componentes asociados al rendimiento o a la aptitud productiva [3–5]. Por tanto, el problema no es la ausencia de técnicas predictivas, sino cómo se evalúan y qué tan comparables son sus resultados cuando cambian la frecuencia de los datos, las variables de entrada y el procedimiento de validación.

Este punto es especialmente sensible en series temporales. Un modelo puede obtener errores bajos si durante el entrenamiento utiliza información que, en una situación real, todavía no estaría disponible. Esa fuga de información produce una evaluación demasiado favorable. Kadir et al. muestran que, cuando todos los modelos se comparan bajo una ventana temporal expansiva y con variables construidas solo desde el pasado, la ventaja de modelos complejos puede ser pequeña frente a referencias simples [6]. En cacao, Nurmawati et al. compararon Naïve, Seasonal Naïve, ETS, ARIMAX, SARIMAX, XGBoost, LSTM y un modelo híbrido sobre un periodo independiente de prueba [7]. Aunque su variable objetivo son exportaciones, el diseño resulta útil para este estudio porque mantiene un mismo horizonte y un mismo periodo de evaluación.

La revisión sistemática de literatura vinculada al proyecto estudia aprendizaje automático y profundo para el pronóstico de producción o rendimiento de cultivos perennes tropicales. Esa revisión incluye cacao, café, palma aceitera, té y caucho para comparar modelos, fuentes, frecuencia de datos, validación y métricas. Sin embargo, el PPI se delimita empíricamente al cacao. Los otros cultivos cumplen una función de referencia metodológica dentro de la RSL, pero no forman parte del objeto principal del experimento presentado aquí.

Para el caso peruano, MIDAGRI/SIEA publica anuarios de Producción Agrícola con información regional y mensual que puede utilizarse para construir series temporales [8]. La integración de los anuarios 2017–2023 permitió identificar 16 series regionales activas de cacao, equivalentes a 1,344 observaciones región–mes. Esta cobertura supera la limitación encontrada en la primera versión del proyecto, que dependía de un número reducido de registros de una sola provincia.

Contar con más observaciones no resuelve por sí mismo la pregunta de investigación. Todavía debe comprobarse si un modelo de aprendizaje automático mejora realmente una referencia estacional cuando el orden temporal se respeta y el periodo final permanece fuera

del entrenamiento. Por esa razón, el estudio utiliza Seasonal Naïve como referencia obligatoria y reserva 2023 como prueba fuera de muestra. El error absoluto escalado medio, MASE, será la métrica principal porque permite expresar si el modelo mejora o empeora frente a una referencia sencilla [9]. MAE, RMSE y sMAPE se utilizarán como métricas complementarias.

En consecuencia, la pregunta general es:

¿Qué desempeño predictivo alcanzan los modelos estadísticos y de aprendizaje automático para el pronóstico mensual de la producción regional de cacao en el Perú, y en qué medida superan una referencia estacional bajo un esquema de validación temporal?

Problemas específicos

PE1. ¿Qué cobertura temporal y territorial presentan las series mensuales de producción de cacao disponibles en los anuarios agrícolas 2017–2023?

PE2. ¿Qué variables temporales pueden construirse sin utilizar información futura para pronosticar la producción mensual regional de cacao?

PE3. ¿Qué desempeño presentan Seasonal Naïve, los modelos estadísticos seleccionados y los modelos de aprendizaje automático mediante MASE, MAE, RMSE y sMAPE bajo validación temporal?

PE4. ¿Qué modelo presenta el menor error fuera de muestra para cacao y qué limitaciones aparecen al comparar modelos de distinta complejidad?

1.2. Objetivos

Objetivo general

Evaluar el desempeño de modelos estadísticos y de aprendizaje automático para el pronóstico mensual de la producción regional de cacao en el Perú utilizando datos agrícolas abiertos, mediante un esquema de validación temporal.

Objetivos específicos

OE1. Integrar y caracterizar los registros mensuales de producción de cacao disponibles en los anuarios agrícolas nacionales del periodo 2017–2023.

OE2. Construir un conjunto analítico reproducible mediante control de calidad, armonización territorial y generación de variables temporales calculadas únicamente con información disponible antes del periodo a pronosticar.

OE3. Implementar una referencia Seasonal Naïve, modelos estadísticos y modelos de aprendizaje automático bajo un mismo horizonte y protocolo de validación temporal.

OE4. Comparar el desempeño fuera de muestra mediante MASE, MAE, RMSE y sMAPE, identificando el modelo con menor error y sus principales limitaciones.

1.3. Hipótesis

Hipótesis alternativa (H1): al menos uno de los modelos de aprendizaje automático evaluados obtiene un error menor que la referencia Seasonal Naïve para el pronóstico mensual de producción regional de cacao, expresado por un valor de $MASE < 1$ en el periodo de prueba fuera de muestra.
Hipótesis nula (H0): ninguno de los modelos de aprendizaje automático evaluados mejora a la referencia Seasonal Naïve; es decir, todos presentan $MASE \geq 1$ en el periodo de prueba fuera de muestra.

1.4. Justificación

Justificación práctica

Un pronóstico mensual puede aportar una referencia anticipada para el seguimiento de la producción y para el análisis de variaciones regionales. El trabajo no reemplaza la estimación oficial ni pretende explicar por sí solo las causas agronómicas de cada cambio. Su utilidad está en evaluar si la información histórica publicada contiene patrones suficientes para estimar el mes siguiente con un error menor que una referencia estacional.

Justificación metodológica

El estudio compara todos los modelos bajo un mismo orden temporal, horizonte y periodo de prueba. Esta decisión reduce el riesgo de evaluar un algoritmo con información futura o con divisiones aleatorias que no representan una situación real de pronóstico. La metodología también obliga a incluir Seasonal Naïve y, cuando corresponda, modelos estadísticos como ETS o ARIMA/SARIMA antes de interpretar el desempeño de los modelos de aprendizaje automático [10, 11].

Justificación tecnológica

Desde Ingeniería de Sistemas, el proyecto articula integración de datos, trazabilidad, construcción de características, entrenamiento, validación y control de versiones. El producto no será únicamente una tabla de métricas. Se documentará el flujo de datos y los experimentos para que las ejecuciones puedan repetirse y compararse. Los scripts, configuraciones y resultados se organizarán en un repositorio GitHub con commits por hito del trabajo.

Justificación académica

El PPI se mantiene conectado con la RSL y con el short paper. La RSL aporta el marco de comparación entre ML, DL, baselines y validación; el PPI aplica ese marco al caso peruano del cacao; y el short paper resume el primer experimento fuera de muestra. Esta continuidad evita que los entregables respondan a preguntas diferentes.

1.5. Antecedentes

Antecedentes internacionales

Tosto et al. revisaron enfoques de modelamiento de producción de cacao y señalaron que la disponibilidad y calidad de datos siguen condicionando la calibración y validación de modelos [12]. Olofintuyi et al. propusieron un ensamble profundo para rendimiento de cacao [1], mientras que Nurmawati et al. compararon modelos estadísticos, ML, DL e híbridos para exportaciones de cacao de Indonesia con un periodo independiente de prueba [7]. Estos trabajos confirman que el problema predictivo admite distintas familias de modelos, pero también muestran que el resultado depende del objetivo y del protocolo de evaluación.

Estudios en otros cultivos perennes aportan decisiones metodológicas útiles. Khan et al. utilizaron 420 meses de información para estimar rendimiento de palma aceitera con variables meteorológicas y de humedad del suelo [13]. Kouadio et al. estudiaron pronóstico probabilístico de café Robusta con índices agroclimáticos y de teledetección [14]. Lee et al. compararon modelos de panel y series temporales para pronóstico agrícola subnacional [15]. Estos antecedentes respaldan el uso de datos mensuales regionales y la necesidad de comparar enfoques bajo una misma partición temporal.

Antecedentes nacionales

Porras y Ovalle aplicaron LSTM a la producción de cacao peruano [2]. Más recientemente, Zabaleta-Santisteban et al. evaluaron aptitud geoespacial del cacao en Amazonas mediante un ensamble que incluyó Random Forest y XGBoost, usando variables ambientales y territoriales [4]. Aunque estos trabajos responden a objetivos distintos, muestran que existen antecedentes nacionales suficientes para evitar afirmar que el uso de ML en cacao peruano es inexistente.

El vacío del presente estudio es más específico. Se requiere una comparación reproducible de producción mensual regional de cacao peruano que incluya una referencia estacional, mantenga el orden temporal, reserve un periodo final fuera de muestra y documente las decisiones de preparación y entrenamiento. Esa combinación define el aporte del PPI.

1.6. Marco conceptual

Serie temporal y horizonte de pronóstico

Una serie temporal es una secuencia de observaciones ordenadas por fecha. En este trabajo cada serie corresponde a la producción mensual de una región. El horizonte principal es de un mes, por lo que la producción del mes t se estima usando información disponible hasta $t-1$.

Rezagos y estacionalidad

Un rezago representa el valor observado varios periodos antes. Por ejemplo, y_{t-12} corresponde a la producción del mismo mes del año anterior. Este rezago es especialmente útil cuando existe un patrón anual. Las variables calendario también pueden codificarse con seno y coseno para representar que diciembre y enero son meses consecutivos dentro del ciclo.

Seasonal Naïve

Seasonal Naïve utiliza como pronóstico el valor observado en la misma estación previa. Para una serie mensual con estacionalidad anual:

$$\hat{y}_t = y_{t-12}. \tag{1}$$

Su función es actuar como referencia. Un modelo más complejo debe demostrar que reduce el error frente a este comportamiento antes de ser considerado una mejora.

MASE

MASE compara el error absoluto del modelo con el error de una referencia ingenua [9]. En términos de interpretación, valores menores que uno indican una mejora frente a la referencia utilizada. Esta propiedad facilita comparar modelos sin depender únicamente de la escala de producción de cada región.

Validación temporal y fuga de información

La validación temporal conserva el orden cronológico entre entrenamiento y evaluación. La fuga de información ocurre cuando el modelo utiliza datos que todavía no estarían disponibles al momento de producir el pronóstico. Para reducir este riesgo, los rezagos, promedios móviles y escaladores se calculan utilizando exclusivamente información histórica del conjunto correspondiente.

2. Metodología

2.1. Enfoque, tipo y diseño de investigación

La investigación tendrá enfoque cuantitativo y carácter aplicado, porque trabaja con registros numéricos y evalúa modelos computacionales sobre un problema concreto de pronóstico agrícola. El diseño será no experimental, ya que no se modifican las condiciones de producción ni se interviene sobre productores o cultivos. También será longitudinal y predictivo, debido a que analiza observaciones mensuales ordenadas entre 2017 y 2023 y estima periodos posteriores a partir de información histórica.

El estudio se desarrollará como un experimento computacional reproducible. Cada modelo recibirá variables construidas bajo el mismo origen temporal y será evaluado sobre periodos que no participaron en su ajuste. Esta condición busca que la comparación represente capacidad de generalización y no memoria sobre los datos de entrenamiento.

2.2. Fuente de datos y cobertura

La fuente principal corresponde a los cuadros en Excel de los anuarios de Producción Agrícola publicados por MIDAGRI/SIEA [8]. Se integraron los archivos disponibles entre 2017 y 2023 y se extrajeron las tablas mensuales regionales de cacao.

La selección de series se definió antes de observar los resultados del test. Una región fue considerada activa cuando registró producción positiva en al menos cuatro de los cinco años comprendidos entre 2017 y 2021. Con este criterio se obtuvieron 16 series regionales de cacao. Cada una contiene 84 meses entre enero de 2017 y diciembre de 2023, para un total de 1,344 observaciones región–mes.

Cuadro 1: Cobertura del conjunto de cacao utilizado en el estudio

Elemento	**Valor**
Periodo	2017–2023
Frecuencia	Mensual
Series regionales activas	16
Meses por serie	84
Observaciones región–mes	1,344
Observaciones del test 2023	192

2.3. Unidad de análisis y variables

La unidad de análisis será una observación región–mes. La variable objetivo es la producción mensual de cacao expresada en toneladas. El horizonte principal será de un mes, por lo que la producción del mes t será pronosticada con información disponible como máximo hasta $t - 1$.

Cuadro 2: Variables previstas para el conjunto analítico

Variable	**Tipo**	**Uso**
Producción mensual	Objetivo	Toneladas producidas por región y mes.
Lag 1, 2, 3, 6 y 12	Temporal	Producción registrada uno, dos, tres, seis y doce meses antes.
Promedios móviles 3, 6 y 12	Temporal	Resumen de producción histórica calculado solo con meses anteriores.
Precio rezagado	Exógena disponible	Precio en chacra de periodos anteriores, cuando la tabla correspondiente permita una integración consistente.
Mes seno/coseno	Calendario	Representación cíclica de la estacionalidad mensual.
Región	Categórica	Identificación de diferencias territoriales entre series.
Tendencia	Temporal	Orden acumulado del periodo para representar cambios graduales.

No se utilizará rendimiento del mismo mes como predictor de producción del mismo mes. Producción, área cosechada y rendimiento mantienen una relación dimensional directa, por lo que introducir rendimiento contemporáneo puede entregar información derivada del propio objetivo. Variables climáticas como lluvia, temperatura u ONI se evaluarán después,

siempre que exista una fuente compatible por región y mes y que sus valores puedan conocerse antes del origen del pronóstico.

2.4. Control de calidad y trazabilidad

El trabajo previo de calidad de datos se mantiene como etapa de preparación. Se conservarán los campos originales junto con versiones canónicas para región y fecha. Las reglas de control revisarán estructura, valores faltantes, duplicados, consistencia de unidades y correspondencia entre totales mensuales y anuales.

En el Gate 0 ejecutado sobre los anuarios integrados se comprobó que las sumas mensuales reproducen los totales anuales en las combinaciones revisadas. También se detectaron rótulos territoriales alterados en archivos recientes. Estos valores se conservaron en una columna original y se corrigieron únicamente en una columna canónica usada por el modelo. Estas verificaciones no demuestran que cada observación sea agronómicamente exacta; verifican que la integración mantenga una estructura coherente y trazable.

2.5. Ingeniería de características

Las características temporales se generarán después de ordenar cada serie por fecha. Para cada región se calcularán rezagos de producción $t-1$, $t-2$, $t-3$, $t-6$ y $t-12$. Los promedios móviles de tres, seis y doce meses se calcularán con observaciones históricas y luego se desplazarán un periodo antes de utilizarse como entrada.

El precio en chacra, cuando se incorpore, se utilizará mediante rezagos. El mes se codificará con funciones seno y coseno para representar el ciclo anual. Cualquier escalamiento requerido por un modelo se ajustará usando únicamente el conjunto de entrenamiento y luego se aplicará sin recalcular parámetros sobre validación o prueba. Este criterio reduce el riesgo de fuga de información [6, 16].

2.6. Modelos a evaluar

La comparación se organizará por niveles. Seasonal Naïve será la referencia obligatoria. En el bloque estadístico se evaluarán ETS y ARIMA/SARIMA cuando la longitud de las series y los diagnósticos permitan estimarlos de forma estable. En aprendizaje automático se incluirán Ridge, Random Forest, Extra Trees y XGBoost. La comparación no asumirá que un modelo de mayor complejidad debe producir un error menor [6, 7, 11].

El aprendizaje profundo será condicional. LSTM podrá evaluarse como experimento adicional si la cantidad de secuencias efectivas de entrenamiento resulta suficiente y si puede aplicarse bajo el mismo protocolo temporal. La presencia de LSTM y GRU en la RSL no obliga a utilizarlos en el PPI si el tamaño de los datos no permite una comparación justa [17].

2.7. Esquema de validación temporal

El año 2017 se utilizará como historia inicial para construir rezagos. La primera configuración experimental reserva 2018–2021 para entrenamiento, 2022 para validación y 2023

como prueba final fuera de muestra. El conjunto de 2023 no se utilizará para seleccionar hiperparámetros ni para decidir qué regiones se consideran activas.

Para la versión final se aplicará una evaluación *walk-forward* con ventana expansiva. En cada origen el modelo se ajustará solo con meses anteriores y emitirá una predicción de un paso:

$$\mathcal{D}_{train}^{(k)} = \{1, \ldots, t_k\}, \qquad \hat{Y}_{t_k+1} = f\left(\mathcal{D}_{train}^{(k)}\right). \tag{2}$$

Después de cada origen, la ventana incorporará la observación siguiente y continuará hasta completar el periodo de evaluación. Este procedimiento se acerca al uso real del pronóstico, donde el futuro no está disponible cuando el modelo se ajusta [6, 10].

2.8. Ajuste de hiperparámetros y prevención de fuga

Los hiperparámetros se seleccionarán usando únicamente entrenamiento y validación. Para modelos basados en árboles se evaluarán combinaciones acotadas de profundidad, número de árboles, tasa de aprendizaje y regularización. El objetivo será obtener configuraciones comparables sin convertir la búsqueda de hiperparámetros en el objeto central del estudio.

Las reglas para prevenir fuga serán: no utilizar 2023 para seleccionar modelos; calcular rezagos y promedios móviles solo hacia atrás; ajustar escaladores dentro de entrenamiento; no usar variables derivadas del objetivo en el mismo periodo; y conservar el mismo horizonte para todos los modelos. Maatougui et al. aplicaron un criterio similar al realizar el ajuste dentro del conjunto de entrenamiento y mantener un conjunto independiente para evaluación [18].

2.9. Métricas y criterio de comparación

MASE será la métrica principal. También se reportarán MAE, RMSE y sMAPE. No se seleccionará un modelo únicamente por R^2, porque un valor alto no demuestra por sí mismo una mejora frente a una referencia temporal.

La hipótesis se considerará respaldada si al menos un modelo obtiene $MASE < 1$ en la prueba final. También se informará la reducción porcentual de MAE y RMSE respecto de Seasonal Naïve. Si dos modelos presentan errores cercanos, se considerará la prueba de Diebold–Mariano, siempre que la cantidad y estructura de errores permitan una comparación válida [7, 19].

2.10. Procedimiento de trabajo

El procedimiento se organiza en seis fases. La Figura 1 resume la secuencia desde la definición del problema hasta la interpretación de los pronósticos.



Figura 1: Método de trabajo para el pronóstico mensual de producción de cacao.

2.11. Resultados preliminares de factibilidad

Antes de cerrar el diseño se ejecutó una prueba inicial para comprobar que el conjunto integrado admite pronóstico temporal. Se utilizó 2018–2021 como entrenamiento, 2022 como validación y 2023 como prueba. En esta ejecución se comparó Seasonal Naïve con Ridge, Random Forest, Extra Trees y XGBoost.

En cacao, Seasonal Naïve obtuvo un MAE de 131.41 t y un RMSE de 267.19 t. Ridge redujo estos errores a 117.71 t y 227.33 t, respectivamente, y alcanzó un MASE de 0.911. XGBoost obtuvo MASE de 0.989. Random Forest y Extra Trees no superaron la referencia según MASE. El sMAPE de Ridge fue mayor que el de Seasonal Naïve, por lo que el resultado no se interpreta como una superioridad uniforme del modelo.

Cuadro 3: Resultado preliminar para cacao en el test 2023

Modelo	**MAE (t)**	**RMSE (t)**	**sMAPE (%)**	**MASE**
Seasonal Naïve	131.41	267.19	34.31	1.018
Ridge	117.71	227.33	58.30	0.911
Random Forest	142.44	297.46	53.05	1.103
Extra Trees	135.38	262.06	49.53	1.048
XGBoost	127.67	229.76	57.78	0.989

Estos resultados son preliminares. Todavía falta ejecutar el esquema *walk-forward* completo, incorporar los modelos estadísticos definidos y revisar la estabilidad de las diferencias entre ventanas. La comparación final mantendrá los resultados desfavorables; no se eliminarán modelos únicamente porque no superen el baseline.

2.12. Reproducibilidad y evidencias en GitHub

Las evidencias del modelado se organizarán en un repositorio GitHub. El repositorio contendrá scripts de preparación, definición de variables, configuraciones de modelos, archivos de resultados y documentación para repetir las ejecuciones. Cada avance verificable se registrará mediante commits asociados a hitos concretos, por ejemplo: integración del dataset, generación de características, ejecución de baselines, entrenamiento de modelos y evaluación final.

Los archivos fuente oficiales no serán sobrescritos. Cuando su redistribución no sea necesaria, el repositorio almacenará instrucciones para obtenerlos y verificará su procedencia. Los resultados derivados, tablas y configuraciones sí se versionarán para que exista correspondencia entre el código ejecutado y los valores incluidos en el PPI y el short paper.

2.13. Matriz de consistencia

Cuadro 4: Matriz resumida de consistencia del estudio

Pregunta	**Objetivo**	**Variable / indicador**	**Método**
¿Qué cobertura presentan los datos de cacao?	OE1: integrar y caracterizar registros.	Años, regiones, continuidad y N.	Integración y perfilado de series 2017–2023.
¿Qué variables pueden construirse sin fuga?	OE2: construir el conjunto analítico.	Lags, medias móviles, precio rezagado y calendario.	Ingeniería de características usando solo historia disponible.
¿Qué desempeño tienen los modelos?	OE3: implementar referencias, estadísticos y ML.	Predicción mensual por modelo.	Seasonal Naïve, ETS/ARIMA cuando proceda y modelos ML.
¿Qué modelo mejora la referencia?	OE4: comparar desempeño fuera de muestra.	MASE, MAE, RMSE y sMAPE.	Validación temporal y test final 2023.

2.14. Aspectos éticos

La investigación utiliza datos estadísticos abiertos y agregados a nivel regional. No incluye intervención con personas, animales ni recolección de datos personales. Los archivos

oficiales se conservarán con su procedencia y versión. Las transformaciones se realizarán sobre copias de trabajo y no modificarán las fuentes originales.

Los resultados se comunicarán incluyendo limitaciones y resultados desfavorables. No se descartarán modelos o métricas únicamente porque produzcan valores menos convenientes. Cuando una anomalía no pueda resolverse con evidencia documental, se mantendrá registrada y no se corregirá de forma automática.

3. Administración del Proyecto

3.1. Cronograma de actividades

El cronograma actualizado concentra el trabajo restante en actividades que alimentan tanto el PPI como el short paper. La integración del dataset, el Gate 0 y la primera ejecución de modelos ya cuentan con evidencia verificable. Las siguientes semanas se orientan a cerrar la validación temporal, completar los modelos estadísticos, versionar las evidencias en GitHub y preparar la sustentación.

Cuadro 5: Cronograma actualizado del proyecto

Actividad / semana	**1**	**2**	**3**	**4**	**5**	**6**	**7**	**8**
Alineación RSL–PPI y actualización del estado del arte	X	X						
Integración MIDAGRI/SIEA 2017–2023 y selección de series de cacao	X							
QA/QC y documentación del dataset	X	X						
Ingeniería de características y control de fuga		X	X					
Seasonal Naïve y modelos estadísticos			X	X				
Modelos de aprendizaje automático y ajuste			X	X	X			
Validación walk-forward y comparación de métricas				X	X	X		
Versionado de evidencias y commits en GitHub	X	X	X	X	X	X	X	X
Actualización del short paper IEEE		X	X	X	X	X		
Cierre de PPI, matriz y anexos	X	X	X	X	X	X	X	
Integración de artículos restantes de la RSL	X	X	X	X	X	X	X	X
Revisión final y preparación de sustentación						X	X	X

3.2. Productos esperados

Al cierre del proyecto se espera contar con un dataset analítico documentado de producción mensual regional de cacao, código reproducible para entrenamiento y validación, una tabla comparativa de modelos, evidencias versionadas mediante commits y un análisis del comportamiento fuera de muestra. El short paper utilizará el mismo diseño metodológico y los mismos resultados finales para conservar coherencia entre los entregables.

3.3. Gestión de evidencias

Las evidencias computacionales se organizarán por carpetas y por hitos. Como mínimo se conservarán el script de integración, el archivo de configuración de variables, el código de entrenamiento, los archivos CSV con métricas, las figuras generadas y un archivo README

con instrucciones de ejecución. Los commits deberán describir cambios verificables y evitar mensajes genéricos. La URL del repositorio se añadirá al PPI una vez que el repositorio quede creado y revisado.

3.4. Presupuesto proyectado

El estudio utiliza datos abiertos y herramientas de software sin costo de licencia. Los gastos previstos corresponden a conectividad, almacenamiento, posible cómputo en la nube para experimentos de mayor demanda y materiales de presentación.

Cuadro 6: Presupuesto estimado de recursos del proyecto

Recurso	**Cantidad**	**Precio unitario (S/)**	**Total (S/)**
Laptop personal	1	0.00	0.00
Python, R, Jupyter y librerías open source	1	0.00	0.00
Overleaf / LaTeX	1	0.00	0.00
GitHub	1	0.00	0.00
Internet, aporte proporcional	2 meses	50.00	100.00
Almacenamiento o cómputo en nube, si se requiere	1	80.00	80.00
Impresiones y materiales de sustentación	1	60.00	60.00
		TOTAL ESTIMADO	**240.00**

4. Referencias Bibliográficas

Referencias

[1] S. S. Olofintuyi, E. A. Olajubu, and D. Olanike, "An ensemble deep learning approach for predicting cocoa yield," *Heliyon*, vol. 9, no. 4, p. e15245, 2023.

[2] R. Porras and C. Ovalle, "Prediction model for peruvian cocoa production using deep learning and long short-term memory techniques," in *Proceedings of the LACCEI International Multi-Conference for Engineering, Education and Technology*, 2023.

[3] S. Obahoundje, S. A. Tilahun, and P. Schmitter, "Climate–yield interactions in west africa: Machine learning insights for cocoa production in ghana and côte d'ivoire," *PLOS Climate*, vol. 5, no. 7, pp. 1–24, 2026.

[4] J. A. Zabaleta-Santisteban, A. J. Medina-Medina, K. M. Tuesta-Trauco, A. S. Rivera-Fernandez, T. B. Silva-Melendez, M. A. Grandez-Alberca, J. Puscan-Rojas, R. Salas López, M. Oliva-Cruz, A. Cotrina-Sanchez, N. B. Rojas-Briceño, J. O. Silva-López, D. Gómez-Fernández, S. T. Leiva-Espinoza, A. F. Huaman-Pilco, and E. Barboza, "Geospatial suitability of cacao in amazonas (peru): An ensemble predictive modeling approach (biomod2) integrating multisource data, territorial management, and plant health," *PLOS ONE*, vol. 21, no. 10, p. e0360376, 2026.

[5] I. Baek, J. Bhatt, S. Lim, D. Lee, J. H. Jang, S. P. Cohen, A. H. Lovelace, M. S. Kim, L. W. Meinhardt, S. Park, and E. Ahn, "A gwas–machine learning framework reveals protein-synthesis pathway signals for yield in theobroma cacao after population-structure correction," *Scientific Reports*, vol. 16, p. 13840, 2026.

[6] D. H. Kadir, D. M. Khalil, and A. M. Khudhur, "Forecasting multivariate time series: A comparison of machine learning, statistical and deep learning models," *Forecasting*, vol. 8, no. 4, p. 73, 2026.

[7] E. Nurmawati, N. Agustina, R. Kurniawan, P. U. Gio, R. Abyasa, and A. H. K. Putra, "Forecasting cocoa export volumes in indonesia using remote sensing, climate variability, and economic indicators: A comparative modeling approach," *Statistical Journal of the IAOS*, 2026, onlineFirst, published 18 September 2026.

[8] Ministerio de Desarrollo Agrario y Riego, "Compendio anual de producción agrícola," Plataforma del Estado Peruano, 2026, cuadros en Excel de los anuarios 2016–2023; consulta: 9 de noviembre de 2026. [Online]. Available: https://www.gob.pe/institucion/midagri/informes-publicaciones/2730325-compendio-anual-de-produccion-agricola

[9] R. J. Hyndman and A. B. Koehler, "Another look at measures of forecast accuracy," *International Journal of Forecasting*, vol. 22, no. 4, pp. 679–688, 2006.

[10] C. Bergmeir and J. M. Benítez, "On the use of cross-validation for time series predictor evaluation," *Information Sciences*, vol. 191, pp. 192–213, 2012.

[11] S. Makridakis, E. Spiliotis, and V. Assimakopoulos, "The m4 competition: 100,000 time series and 61 forecasting methods," *International Journal of Forecasting*, vol. 36, no. 1, pp. 54–74, 2020.

[12] A. Tosto, A. Morales, E. Rahn, J. B. Evers, P. A. Zuidema, and N. P. R. Anten, "Simulating cocoa production: A review of modelling approaches and gaps," *Agricultural Systems*, vol. 206, p. 103614, 2023.

[13] N. Khan, M. A. Kamaruddin, U. U. Sheikh, M. H. Zawawi, Y. Yusup, M. P. Bakht, and N. Mohamed Noor, "Prediction of oil palm yield using machine learning in the perspective of fluctuating weather and soil moisture conditions: Evaluation of a generic workflow," *Plants*, vol. 11, no. 13, p. 1697, 2022.

[14] L. Kouadio, V. M. Byrareddy, A. Sawadogo, and N. K. Newlands, "Probabilistic yield forecasting of robusta coffee at the farm scale using agroclimatic and remote sensing derived indices," *Agricultural and Forest Meteorology*, vol. 306, p. 108449, 2021.

[15] D. Lee, F. Davenport, S. Shukla, G. Husak, C. Funk, and J. Verdin, "Contrasting performance of panel and time-series data models for subnational crop forecasting in sub-saharan africa," *Agricultural and Forest Meteorology*, vol. 359, p. 110213, 2024.

[16] S. M. Shawon, M. Zaman, S. Maniam, M. Al Qwaid, M. T. Sarker, T. Y. Kheng, and H. Y. Wong, "Explainable quantile cnn-lstm model for uncertainty-aware multi-layer soil

moisture prediction in tropical cocoa plantations," *Scientific Reports*, vol. 16, p. 16994, 2026.

[17] M. Naghdyzadegan Jahromi, A. Gohari, and A. Torabi Haghighi, "Decoding the climate–potato link: six decades of teleconnection-driven european potato yield variability revealed by explainable machine learning," *The Journal of Agricultural Science*, vol. 164, p. e53, 2026.

[18] M. Maatougui, S. Phillips, S. O. Abiola, and D. B. Arnall, "Wheat yield prediction using machine learning, proximal sensing, nitrogen and climate data for oklahoma," *Precision Agriculture*, vol. 27, p. 148, 2026.

[19] F. X. Diebold and R. S. Mariano, "Comparing predictive accuracy," *Journal of Business & Economic Statistics*, vol. 13, no. 3, pp. 253–263, 1995.