Pronóstico mensual de la producción de cacao en el Perú mediante modelos de aprendizaje automático y validación temporal

Frank Pretel Ramos Arisapana
Escuela Profesional de Ingeniería de Sistemas
Universidad Peruana Unión, Juliaca, Perú

***Resumen*—El pronóstico de la producción de cacao requiere un diseño que respete el orden temporal de los datos y que compare los modelos contra referencias simples. Este trabajo presenta una primera evaluación con datos agrícolas abiertos del Perú. Se consolidaron series mensuales regionales de producción de cacao para 2017–2023 a partir de anuarios de MIDAGRI/SIEA. Tras seleccionar las regiones con continuidad previa al periodo de prueba, el conjunto utilizado comprende 16 series regionales y 1 344 observaciones región-mes. Se generaron variables rezagadas y se reservaron los años 2018–2021 para entrenamiento, 2022 para validación y 2023 como prueba fuera de muestra. Se compararon Seasonal Naïve, Ridge, Random Forest, Extra Trees y XGBoost. En las 192 observaciones de 2023, Ridge obtuvo el menor MAE, 117.71 t, y el menor RMSE, 227.33 t, frente a 131.41 t y 267.19 t del Seasonal Naïve. Su MASE fue 0.911. XGBoost presentó un desempeño cercano al baseline, mientras Random Forest y Extra Trees no lo superaron en MAE. Los resultados muestran que una mayor complejidad algorítmica no produce automáticamente un mejor pronóstico y justifican continuar la evaluación con validación walk-forward, modelos estadísticos y variables exógenas antes de incorporar aprendizaje profundo.**

***Index Terms*—cacao, producción agrícola, aprendizaje automático, series temporales, validación temporal, pronóstico**

I. Introducción y problema

El cacao (*Theobroma cacao* L.) es un cultivo permanente producido en distintas regiones del Perú y su volumen mensual cambia durante el año. Para estudiar esa variación no basta con construir un modelo con buenos resultados sobre observaciones mezcladas al azar. Un sistema de pronóstico debe estimar periodos futuros usando únicamente información disponible hasta el momento en que se genera la predicción.

El aprendizaje automático se ha aplicado a rendimiento y producción de cacao mediante redes recurrentes, modelos híbridos y análisis de componentes asociados al rendimiento [1], [2], [11]. Una revisión de modelos de producción de cacao señala además que la disponibilidad de datos para calibración y validación sigue siendo una limitación frecuente [9]. También existen trabajos recientes que emplean XGBoost, LSTM, modelos estadísticos y referencias ingenuas para series relacionadas con cacao [3]. Sin embargo, los resultados de estos estudios dependen de la frecuencia de los datos, de las variables disponibles y de la forma en que se separan entrenamiento y prueba.

Este punto es relevante porque una partición aleatoria puede introducir fuga de información. La fuga ocurre cuando el entrenamiento utiliza directa o indirectamente datos que no estarían disponibles al momento de pronosticar. En series temporales, la consecuencia puede ser una estimación demasiado favorable del desempeño. Estudios recientes sobre forecasting agrícola y de commodities han mostrado que, bajo una evaluación cronológica común, modelos de mayor complejidad pueden quedar cerca de métodos simples [4].

El trabajo se concentra en una pregunta: ¿los modelos de aprendizaje automático evaluados reducen el error del pronóstico mensual regional de cacao en el Perú frente a una referencia estacional cuando se reserva un periodo final fuera de muestra? El aporte es una comparación reproducible construida sobre datos públicos peruanos, con características obtenidas solo desde la historia disponible y con 2023 separado de las decisiones de entrenamiento.

II. Antecedentes y vacío de conocimiento

La literatura revisada confirma que el cacao ya ha sido tratado mediante técnicas predictivas, por lo que el vacío no consiste en afirmar que el aprendizaje automático no se haya aplicado al cultivo. Porras y Ovalle propusieron un modelo LSTM para producción de cacao peruano [1]. Olofintuyi *et al.* combinaron CNN, RNN y LSTM para rendimiento de cacao en Nigeria [2]. En Indonesia, Nurmawati *et al.* compararon Naïve, Seasonal Naïve, ETS, ARIMAX, SARIMAX, XGBoost, LSTM y un modelo híbrido para exportaciones de cacao, con un periodo independiente de prueba [3].

Otros trabajos ayudan a delimitar decisiones metodológicas. En palma aceitera se han comparado múltiples algoritmos de ML y DL usando información agronómica y climática [5], [6]; un estudio reciente en Tailandia incorporó producción provincial y lluvia para comparar regresión lineal, Random Forest, Gradient Boosting y XGBoost [12]. Para café Robusta, Kadir *et al.* aplicaron una ventana expansiva *walk-forward* y encontraron que XGBoost presentó la mejor precisión numérica, aunque su ventaja frente a Naïve y ARIMA fue pequeña [4]. En cacao también existen aplicaciones de CNN-LSTM a humedad del suelo y de ensambles a aptitud geoespacial en Amazonas, Perú [7], [8]; estos trabajos no pronostican producción mensual, pero muestran la utilidad de variables ambientales y evaluaciones independientes.

A partir de estos antecedentes, el vacío se delimita a la evaluación de producción mensual regional de cacao peruano

Cuadro I
ANTECEDENTES CERCANOS Y DIFERENCIA CON EL OBJETO DEL ESTUDIO

Referencia	Contribución utilizada	Diferencia con este trabajo
Porras y Ovalle [1]	LSTM aplicado a producción de cacao en Perú.	El presente estudio compara varios modelos y reserva un test temporal explícito.
Olofintuyi *et al.* [2]	Ensamble CNN–RNN–LSTM para rendimiento de cacao.	El objetivo aquí es producción mensual regional, no rendimiento.
Nurmawati *et al.* [3]	Baselines, modelos estadísticos, XGBoost, LSTM y test independiente.	Su variable objetivo es volumen de exportación de cacao en Indonesia.
Kadir *et al.* [4]	Comparación leakage-free con ventana expansiva y modelos estadísticos, ML y DL.	Predice precio de café Robusta, no producción agrícola.
Zabaleta-Santisteban *et al.* [8]	RF y XGBoost con variables ambientales para cacao en Amazonas.	Modela aptitud territorial y no una serie temporal de producción.

Cuadro II
COMPOSICIÓN DEL CONJUNTO UTILIZADO

Elemento	Valor
Periodo consolidado	2017–2023
Series regionales de cacao	16
Meses por serie	84
Observaciones región-mes	1 344
Observaciones del test 2023	192
Variable objetivo	Producción (t)

bajo un mismo protocolo temporal, incluyendo una referencia estacional y un periodo final no utilizado para ajustar los modelos. Esta delimitación evita atribuir a la complejidad del algoritmo mejoras que podrían deberse al procedimiento de evaluación.

III. OBJETO, PREGUNTA Y DATOS

El objeto de estudio es la producción mensual regional de cacao. La unidad de análisis corresponde a una región en un mes determinado. Los datos fueron obtenidos de los anuarios oficiales de producción agrícola publicados por MIDAGRI/SIEA [13]. Se integraron los archivos de 2017 a 2023 y se homologaron los nombres territoriales conservando el dato original y una etiqueta canónica para cada región.

La selección de series se realizó sin consultar 2022 ni 2023. Una región fue considerada activa cuando registró producción en al menos cuatro de los cinco años comprendidos entre 2017 y 2021. Con este criterio se obtuvieron 16 series regionales. Cada serie contiene 84 meses entre enero de 2017 y diciembre de 2023, para un total de 1 344 observaciones región-mes. El conjunto final de prueba corresponde a 2023 y contiene 192 observaciones.

Como control adicional, se comparó para cada región y año la suma de los doce valores mensuales contra el total anual reportado en la misma hoja. En las 112 combinaciones región-año correspondientes a las 16 series seleccionadas y siete años, ambas cantidades coincidieron dentro de la precisión numérica del archivo. Este control no demuestra que cada valor publicado sea correcto, pero sí descarta una inconsistencia entre el bloque mensual usado para modelar y el agregado anual de la fuente.

La Fig. 1 muestra la suma mensual de producción de las 16 series seleccionadas. Se observa un patrón que vuelve a aparecer cada año, con aumentos concentrados en meses similares, aunque la amplitud cambia entre campañas. Esta repetición respalda el uso de un rezago de doce meses y justifica que Seasonal Naïve sea una referencia más exigente que un promedio general.

IV. MÉTODO Y REPRODUCIBILIDAD

IV-A. Preparación y características

Antes del entrenamiento se verificó continuidad mensual, correspondencia territorial y consistencia de los agregados. En las series seleccionadas no se identificaron meses faltantes de producción. Las transformaciones se aplicaron sobre una capa analítica, sin sustituir los valores originales de los anuarios.

Para cada región se generaron rezagos de producción en $t-1$, $t-2$, $t-3$, $t-6$ y $t-12$, además de medias móviles históricas y variables cíclicas para el mes. Un rezago es simplemente un valor observado en un periodo anterior. Las medias móviles se calcularon antes del mes objetivo y luego se desplazaron, de modo que una predicción para t no utilice información de t o de periodos posteriores. El precio rezagado se incluyó cuando estuvo disponible en la tabla integrada.

IV-B. Separación temporal

Los registros derivados de 2017 proporcionan la historia inicial necesaria para construir rezagos. El entrenamiento principal utiliza 2018–2021, 2022 funciona como validación para seleccionar configuraciones y 2023 se mantiene como prueba final. El esquema es

$$\text{entrenamiento} < \text{validación} < \text{prueba}. \tag{1}$$

No se utiliza un *random split* como evaluación principal. La versión posterior del estudio ampliará este diseño mediante *walk-forward*, donde el entrenamiento crece cronológicamente y cada pronóstico se genera desde un nuevo origen temporal.

IV-C. Modelos y referencia

La referencia es Seasonal Naïve. Para el mes t, este método reutiliza la producción observada doce meses antes:

$$\hat{y}_t = y_{t-12}. \tag{2}$$

Su presencia evita evaluar un algoritmo únicamente contra sí mismo o contra un promedio sin estacionalidad.

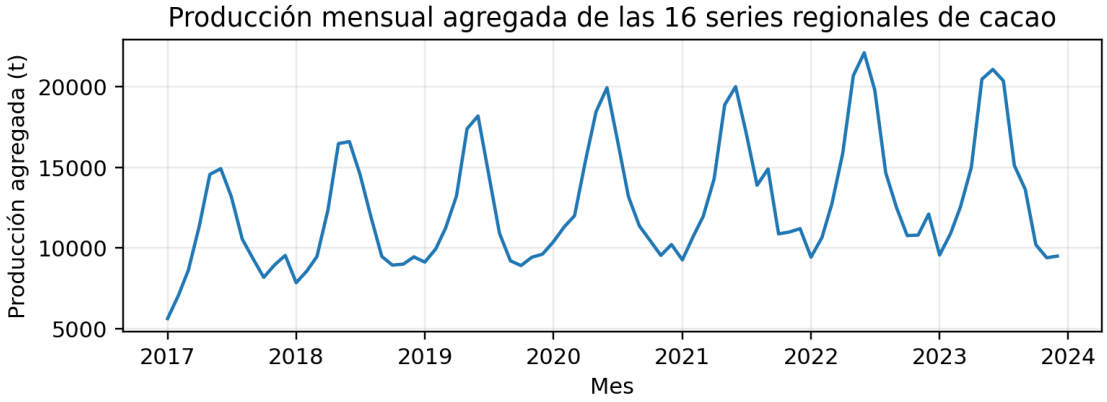


Figura 1. Producción mensual agregada de las 16 series regionales de cacao utilizadas, 2017–2023.

Cuadro III
DESEMPEÑO FUERA DE MUESTRA EN 2023

Modelo	MAE (t)	RMSE (t)	sMAPE (%)	MASE
Seasonal Naïve	131.41	267.19	34.31	1.018
Ridge	**117.71**	**227.33**	58.30	**0.911**
XGBoost	127.67	229.76	57.78	0.989
Extra Trees	135.38	262.06	49.53	1.048
Random Forest	142.44	297.46	53.05	1.103

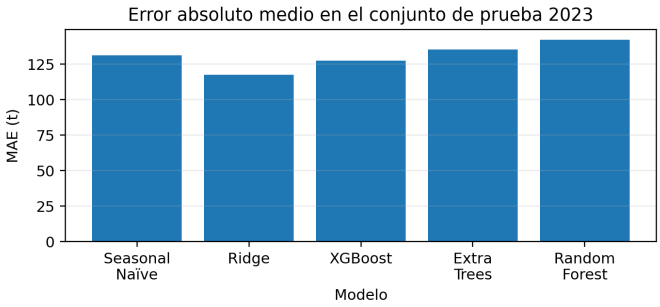


Figura 2. MAE de los modelos evaluados sobre el conjunto de prueba 2023.

Se entrenaron Ridge, Random Forest, Extra Trees y XGBoost. Ridge es una regresión lineal con regularización, es decir, incorpora una penalización que limita coeficientes excesivos. Los otros tres modelos usan árboles de decisión y pueden representar relaciones no lineales entre rezagos y producción. Los parámetros se seleccionaron con el conjunto de validación 2022 y luego cada modelo fue reajustado con la información disponible hasta el cierre de ese año antes de evaluar 2023.

Las métricas utilizadas fueron MAE, RMSE, sMAPE, R^2 y MASE. El MAE expresa el error absoluto medio en toneladas y el RMSE aumenta el peso de errores grandes. MASE escala el error respecto a una referencia temporal; valores menores que uno indican un error medio inferior a la escala de referencia utilizada durante el cálculo.

V. RESULTADOS Y ANÁLISIS

La Tabla III presenta el desempeño sobre las 192 observaciones región-mes de 2023. Seasonal Naïve obtuvo un MAE de 131.41 t y un RMSE de 267.19 t. Ridge redujo estas cifras a 117.71 t y 227.33 t, respectivamente. La reducción equivale aproximadamente a 10.43 % en MAE y 14.92 % en RMSE frente al baseline. Su MASE fue 0.911.

XGBoost obtuvo un MAE de 127.67 t y un RMSE de 229.76 t, por lo que quedó cerca del baseline en error absoluto. Extra Trees y Random Forest no lo superaron según MAE. El comportamiento de sMAPE fue distinto: Seasonal Naïve obtuvo el menor valor porcentual, mientras Ridge y XGBoost mostraron errores relativos mayores. Esta diferencia ocurre porque las regiones tienen escalas productivas distintas y los errores porcentuales aumentan cuando los valores observados son pequeños. Por ello, la selección no se basa en una sola métrica.

El resultado principal es que la mayor complejidad del modelo no produjo una ventaja uniforme. Ridge, el método entrenado más simple del grupo, alcanzó el menor MAE y RMSE. XGBoost fue competitivo, mientras Random Forest presentó un error superior al Seasonal Naïve. Este patrón es consistente con estudios donde modelos avanzados quedan próximos a referencias simples cuando la evaluación evita información futura [4].

Durante la selección de configuración en 2022, Ridge registró un MAE de 121.08 t, Extra Trees 136.64 t, Random Forest 149.32 t y XGBoost 153.20 t. Estas cifras no se presentan como una segunda prueba independiente porque 2022 intervino en la selección de parámetros. Su utilidad es documentar que el ajuste se realizó antes de abrir el conjunto 2023 y que el orden de desempeño observado en el test no fue construido usando datos de ese año.

VI. DISCUSIÓN Y CONCLUSIONES

La primera evaluación muestra que los datos abiertos de MIDAGRI/SIEA permiten construir un experimento mensual de cacao con separación temporal real. La base utilizada contiene 16 series regionales y 1 344 observaciones, una escala distinta al planteamiento inicial limitado a una sola provincia. El uso

de 2023 como test hace posible discutir desempeño fuera de muestra sin mezclar ese periodo con el ajuste de los modelos.

Ridge obtuvo la mejor combinación de MAE, RMSE y MASE, pero no el menor sMAPE. Por tanto, el resultado no se interpreta como una superioridad general del modelo en todas las condiciones. La evidencia actual indica que los rezagos históricos contienen información predictiva y que un modelo relativamente sencillo puede reducir el error absoluto frente a Seasonal Naïve. También muestra que entrenar un algoritmo de árboles más complejo no garantiza una mejora.

El trabajo todavía tiene límites. No se han incorporado ETS, ARIMA/SARIMA ni modelos de aprendizaje profundo dentro de esta comparación. Tampoco se han añadido lluvia, temperatura, ONI u otras variables ambientales. En cacao, la evidencia experimental muestra que la disponibilidad hídrica y la sequía afectan el crecimiento y el rendimiento [10], mientras otros estudios integran variables ambientales en modelos predictivos [3], [7], [8]. Incluirlas requiere primero alinear cada fuente por región y mes sin introducir datos posteriores al origen del pronóstico.

Otra limitación es la heterogeneidad de escala entre regiones. Una diferencia de cien toneladas puede representar un error pequeño para una región de alta producción y uno grande para una región con valores bajos. Esto explica parte del contraste entre MAE/RMSE y sMAPE. En una versión posterior se reportarán resultados por región y por temporada para identificar si la mejora promedio se concentra en determinados territorios o meses. También se evaluará la estabilidad de las conclusiones frente a distintos horizontes de pronóstico.

El siguiente paso será aplicar una evaluación *walk-forward* común a todos los modelos, agregar referencias estadísticas y comprobar si las diferencias de error se mantienen en distintos orígenes temporales. La inclusión de LSTM u otras redes quedará condicionada por la cantidad efectiva de secuencias disponibles después de separar entrenamiento, validación y prueba. Con los resultados actuales, el estudio ya establece una línea reproducible para comparar pronósticos de producción mensual de cacao peruano sin asumir que el algoritmo más complejo debe ser el mejor.

Referencias

[1] R. Porras and C. Ovalle, "Prediction Model for Peruvian Cocoa Production using Deep Learning and Long Short-Term Memory Techniques," in *Proc. 21st LACCEI Int. Multi-Conf.*, 2023, doi: 10.18687/LACCEI2023.1.1.314.

[2] S. S. Olofintuyi, E. A. Olajubu, and D. Olanike, "An ensemble deep learning approach for predicting cocoa yield," *Heliyon*, vol. 9, no. 4, p. e15245, 2023, doi: 10.1016/j.heliyon.2023.e15245.

[3] E. Nurmawati, N. Agustina, R. Kurniawan, P. U. Gio, R. Abyasa, and A. H. K. Putra, "Forecasting cocoa export volumes in Indonesia using remote sensing, climate variability, and economic indicators: A comparative modeling approach," *Statistical Journal of the IAOS*, Online First, 2026, doi: 10.1177/18747655261486415.

[4] D. H. Kadir, D. M. Khalil, and A. M. Khudhur, "Forecasting Multivariate Time Series: A Comparison of Machine Learning, Statistical and Deep Learning Models," *Forecasting*, vol. 8, no. 4, p. 73, 2026, doi: 10.3390/forecast8040073.

[5] E. J. Jamshidi *et al.*, "Predicting oil palm yield using a comprehensive agronomy dataset and 17 machine learning and deep learning models," *Ecological Informatics*, vol. 81, p. 102595, 2024, doi: 10.1016/j.ecoinf.2024.102595.

[6] N. Khan *et al.*, "Prediction of Oil Palm Yield Using Machine Learning in the Perspective of Fluctuating Weather and Soil Moisture Conditions: Evaluation of a Generic Workflow," *Plants*, vol. 11, no. 13, p. 1697, 2022, doi: 10.3390/plants11131697.

[7] S. M. Shawon *et al.*, "Explainable Quantile CNN-LSTM model for uncertainty-aware multi-layer soil moisture prediction in tropical cocoa plantations," *Scientific Reports*, vol. 16, p. 16994, 2026, doi: 10.1038/s41598-026-48517-z.

[8] J. A. Zabaleta-Santisteban *et al.*, "Geospatial suitability of cacao in Amazonas (Peru): An ensemble predictive modeling approach (BIOMOD2) integrating multisource data, territorial management, and plant health," *PLOS ONE*, vol. 21, no. 10, p. e0360376, 2026, doi: 10.1371/journal.pone.0360376.

[9] A. Tosto, A. Morales, E. Rahn, J. B. Evers, P. A. Zuidema, and N. P. R. Anten, "Simulating cocoa production: A review of modelling approaches and gaps," *Agricultural Systems*, vol. 206, p. 103614, 2023, doi: 10.1016/j.agsy.2023.103614.

[10] E. O. Mensah *et al.*, "Combined effects of shade and drought on physiology, growth, and yield of mature cocoa trees," *Science of the Total Environment*, vol. 899, p. 165657, 2023, doi: 10.1016/j.scitotenv.2023.165657.

[11] I. Baek *et al.*, "A GWAS-machine learning framework reveals protein-synthesis pathway signals for yield in Theobroma cacao after population-structure correction," *Scientific Reports*, vol. 16, p. 13840, 2026, doi: 10.1038/s41598-026-42273-w.

[12] S. E. Shuaib, J. Muangprathub, and P. Riyapan, "A lattice-augmented ensemble framework for interpretable climate-informed oil palm yield prediction in Thailand," *Array*, vol. 31, p. 101037, 2026, doi: 10.1016/j.array.2026.101037.

[13] Ministerio de Desarrollo Agrario y Riego, "Compendio anual de Producción Agrícola," Gobierno del Perú, cuadros estadísticos 2017–2023, consulta 2026.